

進捗報告

1 今週やったこと

- TDGA AutoAugment 実験

2 TDGA AutoAugment 実験

先週の強度と温度を変化させる実験において accuracy の遷移を見てるとまだ上がりそうだったのでエポックを 200 から 300 に増やして実験．温度パラメータは $[0.01, 0.08]$ を 0.01 刻み，強度は $[0, 30]$ を 5 刻みで回した．また，温度パラメータは探索中固定である．

cifar-10 のパラメータは 300 エポック，optimizer は SGD，スケジューラはコサインアニーリング (PyTorch の `torch.optim.lr_scheduler.CosineAnnealingLR` を参照) を用いている．これらの値は RandAugment の論文で採用されているものである．またデフォルト拡張としては pad-and-crop，ランダムフリップ，および画素値の正規化を用いている．

図 1 に強度を 15 に固定して温度を変化させた Test accuracy を示す．

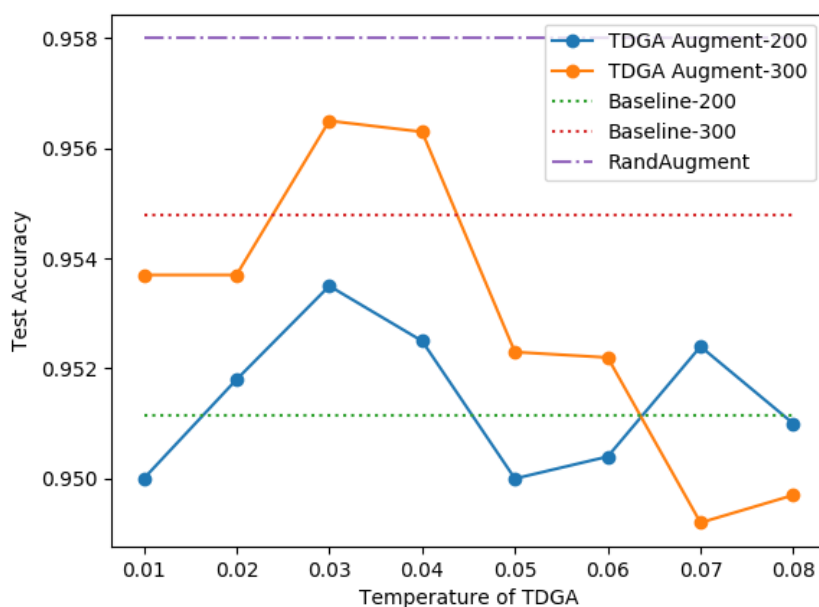


図 1: 温度を変化させた Test accuracy(強度固定)

図 2 に温度を 0.05 に固定して温度を変化させた Test accuracy を示す．

エポックを増やすと accuracy が向上することが確認できた．しかし，baseline からの伸びという点ではそこまでの向上は見られない．得られた拡張も変形を加えないようなものが主であった．この傾向はむしろエポックを増やすほうが顕著に現れそう．

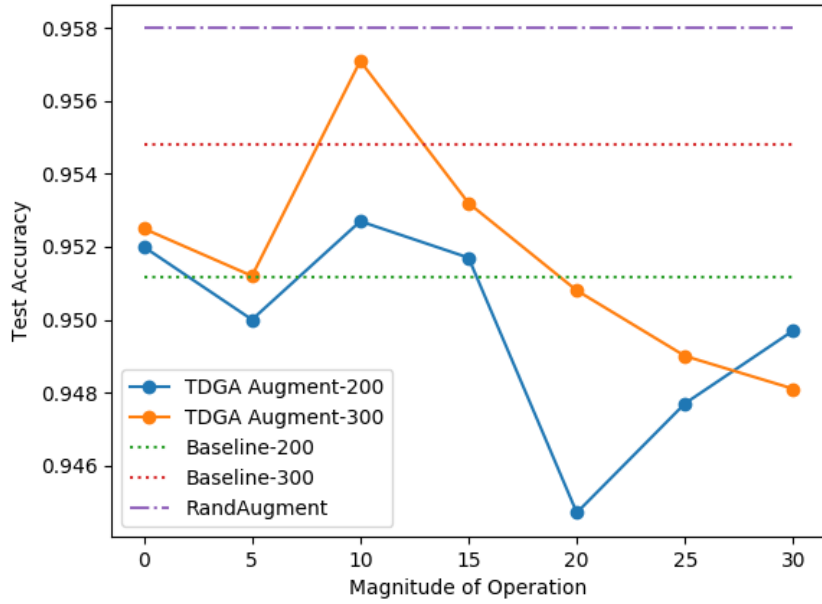


図 2: 強度を変化させた Test accuracy(温度固定)

ここで、図 3 に RandAugment で報告されていた、各操作を採用することによる精度向上の表を示す (正確には表ですがスクショしたので図になっています) . Δ はその操作を選択することで最終精度が向上する期待値を表している .

transformation	Δ (%)	transformation	Δ (%)
rotate	1.3	shear-x	0.9
shear-y	0.9	translate-y	0.4
translate-x	0.4	autoContrast	0.1
sharpness	0.1	identity	0.1
contrast	0.0	color	0.0
brightness	0.0	equalize	-0.0
solarize	-0.1	posterize	-0.3

図 3: 各操作を選択することによる精度への影響

これを見るとやはり変形を加えるようなものの方が精度への寄与は大きいことがわかる . このあたりの多様度をどのように維持するのかということが今後の主な課題になりそう .

表 1 に他手法との比較を示す . 比較に用いた手法は Population Based Augmentation (PBA) [1], Fast AutoAugment (Fast AA) [2], AutoAugment (AA) [3] および RandAugment (RA) [4] である . TDGA Augment 以外の値は RandAugment で掲載されているものである . また , baseline の値は手元で確認した 200 エポック 10 回試行の平均であり , () 内の値は論文で挙げられていたものである . また , Wide-ResNet-28-10 を用いた実験は時間がかかるため (CNN 部分の学習に 200 エポックで 6 時間程度) まずは Wide-ResNet-28-2 でチューニングする .

表 1: Test accuracy(%) on CIFER-10

	baseline	PBA	Fast AA	AA	RA	TDGA Augment
Wide-ResNet-28-2	95.10(94.9)	-	-	95.9	95.8	95.35(300epoch:95.71)
Wide-ResNet-28-10	96.32(96.1)	97.4	97.3	97.4	97.3	-

3 RandAugment の精度が確認できない

今使っている CNN モデルに RandAugment を適用したが、論文通りの精度が出ない。CNN 側に問題がないとすれば transform 側にあるので、少し見直してみているところ。RandAugment を PyTorch で実装しているレポでは実際精度が確認できない系の issue が投げられているので、やや怪しいところではある。

4 次のタスク

操作の種類毎に多様性をもたせるように拡張したい。

5 TODO タスク

- 個体数、世代数の変化による影響の観察
- CIFER-100, SVHN, 漫画画像など他の画像データセットに対する精度比較
- 他のモデルを用いた実験
- 得られた拡張ポリシーの転移学習および Fine Tuning の可能性の調査
- 検出タスクへの適用

参考文献

- [1] Daniel Ho, Eric Liang, Ion Stoica, Pieter Abbeel, and Xi Chen. Population based augmentation: Efficient learning of augmentation policy schedules. *CoRR*, abs/1905.05393, 2019.
- [2] Sungbin Lim, Ildoo Kim, Taesup Kim, Chiheon Kim, and Sungwoong Kim. Fast autoaugment. *CoRR*, abs/1905.00397, 2019.
- [3] Hiroshi Inoue. Data augmentation by pairing samples for images classification. *CoRR*, abs/1801.02929, 2018.
- [4] Ekin D. Cubuk, Barret Zoph, Jonathon Shlens, and Quoc V. Le. Randaugment: Practical automated data augmentation with a reduced search space. *arXiv: Computer Vision and Pattern Recognition*, 2019.